

Análisis estadístico del efecto de la ceniza volante sobre la resistencia del concreto

Camilo Padilla & Juan Campo

2026-10-06

Contents

1	Presentación	5
1.1	Estructura del Documento	5
2	Introducción y Objetivos	7
2.1	Contexto	7
2.2	Problemática	7
2.3	Objetivos del Proyecto	8
2.4	Justificación	8
3	Análisis Exploratorio de Datos (EDA)	9
3.1	Dataset y ficha tecnica	9
3.2	Importamos librerías	9
3.3	Carga de Datos	10
3.4	Diccionario de Variables	10
3.5	Exploración del data set.	11
3.6	Calidad y estructura de los datos	12
3.7	Tabla descriptiva de las variables	13
3.8	Anlisis Univariado de las variables	20
3.9	Analisis Bivariado	24
3.10	Pruebas de normalidad	28

Chapter 1

Presentación

Este proyecto presenta un análisis estadístico de la resistencia a la compresión del concreto a partir del conjunto de datos **Concrete Compressive Strength**, compuesto por 1.030 mezclas experimentales.

El estudio examina la relación entre la incorporación de ceniza volante, el tiempo de curado y la resistencia alcanzada por el concreto. Para ello, se aplican técnicas de análisis exploratorio, pruebas de hipótesis, comparación de grupos, análisis de correlación y modelación estadística, con el propósito de evaluar el comportamiento del material y la viabilidad del uso de la ceniza volante como sustituto parcial del cemento.

1.1 Estructura del Documento

- **Capítulo 1:** Introducción y Objetivos del Estudio.
- **Capítulo 2:** Análisis Exploratorio de Datos (EDA).
- **Capítulos siguientes:** Modelación y Conclusiones.

Chapter 2

Introducción y Objetivos

2.1 Contexto

En la ingeniería civil y los materiales de construcción, la resistencia a la compresión del concreto es una propiedad fundamental que determina la calidad y seguridad de las estructuras. Su propiedad mecánica más crítica es la resistencia a la compresión, ya que determina la capacidad de carga que tiene el material y una estructura de soportar sin colapsar. De forma tradicional, la verificación de resistencia necesita un periodo estándar de 28 días de curado, es decir el proceso de control de la humedad y la temperatura para garantizar que el cemento mantenga la hidratación adecuada durante sus primeras etapas de endurecimiento.

2.2 Problemática

En la industria de la construcción y la ingeniería civil, la resistencia de la compresión de concreto es la propiedad mecánica que garantiza la seguridad de millones de estructuras en el mundo. La sustitución parcial de cemento por ceniza volante también conocido como “fly ash” es una alternativa económica y sostenible en la construcción; sin embargo, al ser un material de reacción lenta, existe incertidumbre sobre si compromete la resistencia del concreto en edades tempranas (1 a 7 días) o si la incrementa con un mayor tiempo de curado (28 a 90+ días).

Por tanto, el problema central radica en determinar estadísticamente: ¿En qué medida el uso de ceniza volante y el tiempo de curado influyen en la resistencia a la compresión del concreto a lo largo de sus distintas etapas de maduración?

2.3 Objetivos del Proyecto

2.3.1 Objetivo general

Evaluar el impacto de la incorporación de ceniza volante (Fly Ash) y del tiempo de curado sobre la resistencia a la compresión del concreto, mediante análisis inferencial y pruebas de hipótesis, para determinar la viabilidad técnica y el comportamiento mecánico de estas formulaciones.

2.3.2 Objetivos específicos

1. Estimar los intervalos de confianza y verificar los supuestos de normalidad para la resistencia del concreto y la dosificación de ceniza volante.
2. Comparar la resistencia media a la compresión entre mezclas con y sin ceniza volante, calculando el tamaño del efecto.
3. Evaluar las diferencias de resistencia entre las etapas de curado (temprana, estándar y tardía) mediante análisis de varianza y pruebas post-hoc.
4. Determinar el grado de correlación entre la cantidad de ceniza volante dosificada y la resistencia alcanzada en el material.

2.4 Justificación

La ceniza volante es un residuo industrial considerablemente más barato que el cemento tradicional; validar su eficacia permite reducir los costos de fabricación de las mezclas sin comprometer la calidad.

Chapter 3

Análisis Exploratorio de Datos (EDA)

En este capítulo analizamos las variables cuantitativas del dataset de Concrete Compressive Strength (Resistencia del Concreto).

3.1 Dataset y ficha tecnica

- **Fuente:** UCI Machine Learning Repository (Donado por el Prof. I-Cheng Yeh, 2007).
- **Área:** Ingeniería Civil / Ciencia de Materiales.
- **Número de Observaciones (N):** 1,030 mezclas experimentales.
- **Número de Variables:** 9 variables cuantitativas (8 independientes + 1 dependiente).
- **Valores Faltantes:** Ninguno.

3.2 Importamos librerías

```
library(tidyverse)
library(moments)
library(patchwork)
library(GGally)
library(dplyr)
```

```
library(effsize)
library(rstatix)
library(lmtest)
library(car)
library(janitor)
library(knitr)
library(kableExtra)
```

3.3 Carga de Datos

```
library(readxl)
Concrete_Data <- read_excel("concrete+compressive+strength/Concrete_Data.xls")

df<- Concrete_Data
```

3.4 Diccionario de Variables

Aclaremos que cada observacion representa un ensayo de laboratorio con una receta individual con ingredientes mezclados para hacer un metro cubico de cemento, el tiempo que se dejo reposar y la fuerza que resistio.

Todas las variables son cuantitativas continuas:

```
diccionario_variables <- tibble(
  variable = c(
    "Cemento", "Escoria de alto horno", "Ceniza volante", "Agua",
    "Superplastificante", "Agregado Grueso", "Agregado Fino", "Edad", "Resistencia"
  ),
  nombre_dataset = c(
    "Cement", "Blast_Furnace_Slag", "Fly_Ash", "Water", "Superplasticizer",
    "Coarse_Aggregate", "Fine_Aggregate", "Age", "Concrete_Compressive_Strength"
  ),
  tipo = c(
    rep("Entrada (Indep.)", 8), "Salida (Dependiente)"
  ),
  unidad = c(
    rep("kg/m^3", 7), "Dias (1 a 365)", "MPa"
  ),
  descripcion = c(
    "Componente aglutinante principal.",
    "Subproducto siderurgico que mejora durabilidad.",
```

```

    "Subproducto de centrales termicas.",
    "Cantidad de agua.",
    "Aditivo quimico que reduce necesidad de agua.",
    "Grava / Piedra chancada.",
    "Arena.",
    "Tiempo de maduracion/curado del concreto.",
    "Resistencia final a la compresion."
  )
)

diccionario_variables |>
  knitr::kable(
    caption = "Diccionario de variables del conjunto de datos",
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position", "scale_down"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.1: Diccionario de variables del conjunto de datos

variable	nombre_dataset	tipo	unidad	descripcion
Cemento	Cement	Entrada (Indep.)	kg/m ³	Componente aglutinante principal.
Escoria de alto horno	Blast_Furnace_Slag	Entrada (Indep.)	kg/m ³	Subproducto siderurgico que mejora durabilidad.
Ceniza volante	Fly_Ash	Entrada (Indep.)	kg/m ³	Subproducto de centrales termicas.
Agua	Water	Entrada (Indep.)	kg/m ³	Cantidad de agua.
Superplastificante	Superplasticizer	Entrada (Indep.)	kg/m ³	Aditivo quimico que reduce necesidad de agua.
Agregado Grueso	Coarse_Aggregate	Entrada (Indep.)	kg/m ³	Grava / Piedra chancada.
Agregado Fino	Fine_Aggregate	Entrada (Indep.)	kg/m ³	Arena.
Edad	Age	Entrada (Indep.)	Dias (1 a 365)	Tiempo de maduracion/curado del concreto.
Resistencia	Concrete_Compressive_Strength	Salida (Dependiente)	MPa	Resistencia final a la compresion.

3.5 Exploración del data set.

Resumimos los nombres de las variables

```

df_clean <- df %>%
  rename(
    cemento      = `Cement (component 1)(kg in a m^3 mixture)`,
    escoria      = `Blast Furnace Slag (component 2)(kg in a m^3 mixture)`,
    ceniza       = `Fly Ash (component 3)(kg in a m^3 mixture)`,
    agua         = `Water (component 4)(kg in a m^3 mixture)`,
    superplast   = `Superplasticizer (component 5)(kg in a m^3 mixture)`,
    agregado_grueso = `Coarse Aggregate (component 6)(kg in a m^3 mixture)`,
  )

```

```

    agregado_fino = `Fine Aggregate (component 7)(kg in a m^3 mixture)`,
    edad          = `Age (day)`,
    resistencia    = `Concrete compressive strength(MPa, megapascals)`
  )

```

3.6 Calidad y estructura de los datos

```

calidad_datos <- tibble(
  variable = names(df_clean),
  clase = map_chr(df_clean, ~ class(.x)[1]),
  tipo = map_chr(df_clean, typeof),
  faltantes = map_int(df_clean, ~ sum(is.na(.x))),
  valores_unicos = map_int(df_clean, n_distinct)
)

calidad_datos |>
  knitr::kable(
    caption = "Calidad y estructura de los datos",
    digits = 0,
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.2: Calidad y estructura de los datos

variable	clase	tipo	faltantes	valores_unicos
cemento	numeric	double	0	280
escoria	numeric	double	0	187
ceniza	numeric	double	0	163
agua	numeric	double	0	205
superplast	numeric	double	0	155
agregado_grueso	numeric	double	0	284
agregado_fino	numeric	double	0	304
edad	numeric	double	0	14
resistencia	numeric	double	0	938

```

duplicados <- tibble(
  indicador = "Filas duplicadas",
  cantidad = sum(duplicated(df_clean))
)

duplicados |>
  knitr::kable(
    caption = "Filas duplicadas del conjunto de datos",
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.3: Filas duplicadas del conjunto de datos

indicador	cantidad
Filas duplicadas	25

3.7 Tabla descriptiva de las variables

```

tabla_descriptiva <- df_clean |>
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "valor"
  ) |>
  group_by(variable) |>
  summarise(
    n = sum(!is.na(valor)),
    media = mean(valor, na.rm = TRUE),
    sd = sd(valor, na.rm = TRUE),
    mediana = median(valor, na.rm = TRUE),
    RIC = IQR(valor, na.rm = TRUE),
    Q1 = quantile(valor, 0.25, na.rm = TRUE),
    Q3 = quantile(valor, 0.75, na.rm = TRUE),
    minimo = min(valor, na.rm = TRUE),
    maximo = max(valor, na.rm = TRUE),
  )

```

```

    asim = skewness(valor, na.rm = TRUE),
    curtosis = kurtosis(valor, na.rm = TRUE),
    .groups = "drop"
  )

tabla_descriptiva |>
  knitr::kable(
    caption = "Estadísticas descriptivas de las nueve variables",
    digits = 3,
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position", "scale_down"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.4: Estadísticas descriptivas de las nueve variables

variable	n	media	sd	mediana	RIC	Q1	Q3	minimo	maximo	asim	curtosis
agregado_fino	1030	773.579	80.175	779.510	93.050	730.950	824.000	594.000	992.600	-0.253	2.893
agregado_grueso	1030	972.919	77.754	968.000	97.400	932.000	1029.400	801.000	1145.000	-0.040	2.398
agua	1030	181.566	21.356	185.000	27.100	164.900	192.000	121.750	247.000	0.074	3.116
cemento	1030	281.166	104.507	272.900	157.625	192.375	350.000	102.000	540.000	0.509	2.476
ceniza	1030	54.187	63.996	0.000	118.270	0.000	118.270	0.000	200.100	0.537	1.672
edad	1030	45.662	63.170	28.000	49.000	7.000	56.000	1.000	365.000	3.264	15.104
escoria	1030	73.895	86.279	22.000	142.950	0.000	142.950	0.000	359.400	0.800	2.489
resistencia	1030	35.818	16.706	34.443	22.429	23.707	46.136	2.332	82.599	0.416	2.682
superplast	1030	6.203	5.973	6.350	10.160	0.000	10.160	0.000	32.200	0.907	4.401

3.7.1 Exploración de la variable de respuesta

```

tabla_resistencia <- df_clean %>% summarise(n = length(resistencia),
      media = mean(resistencia),
      sd = sd(resistencia),
      mediana = median(resistencia),
      RIC = IQR(resistencia),
      Q1 = quantile(resistencia, 0.25),
      Q3 = quantile(resistencia, 0.75),
      minimo = min(resistencia),
      maximo = max(resistencia),
      asim = skewness(resistencia),
      curtosis = kurtosis(resistencia))

```

```

tabla_resistencia |>
  knitr::kable(
    caption = "Estadísticas descriptivas de la resistencia a la compresion",
    digits = 3,
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position", "scale_down"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.5: (#tab:Concrete Compressive strenght)Estadísticas descriptivas de la resistencia a la compresion

n	media	sd	mediana	RIC	Q1	Q3	minimo	maximo	asim	curtosis
1030	35.818	16.706	34.443	22.429	23.707	46.136	2.332	82.599	0.416	2.682


Vemos que las 1030 observaciones de mezclas de concreto, tienen una resistencia de compresion de 35.817 MPa, con una desviación estándar de 16.70 MPa. Además, el 50% de las mezclas tienen una resistencia igual o menor a 34.442 MPa. Además, se observa una mezcla de concreto experimental con resistencia de 85.59 MPa siendo esta la observación con mayor Resistencia final a la compresión y otras con la minima resistencia entre las observaciones con 2.33 MPa.

```

options(scipen = 999)
df_clean |>
  ggplot(aes(x = resistencia)) +
  geom_histogram(
    aes(y = after_stat(density)),
    binwidth = 2,
    fill = "darkblue",
    color = "white",
    alpha = 0.6
  ) +
  geom_density(color = "darkblue", linewidth = 1.2) +
  labs(
    title = "Distribución de la resistencia del concreto",
    x = "Resistencia",
    y = "Densidad"
  ) +
  theme_bw()

```

Distribución de la resistencia del concreto



la resistencia muestra una distribución con forma parecida a una **simétrica con forma de campana**, centrada en torno a los 35 MPa y abarcando un rango desde los 2.3 hasta los 82.6 MPa. La curva de densidad sugiere un comportamiento cercano a la **distribución normal**, reflejando una muestra equilibrada que abarca desde concretos convencionales hasta mezclas de alto rendimiento.

Exploracion de las variables independientes

Creamos la siguiente tabla para observar de forma descriptiva las variables independientes que analizaremos y así complementar el análisis de los boxplots con ella.

```
tabla_independientes <- df_clean |> select(ceniza, edad) |>
  pivot_longer(
    cols = everything(),
    names_to = 'variables',
    values_to = 'valor'
  ) |>
```

```

group_by(variables) |>
  summarise(
    n = length(valor),
    media = round(mean(valor), 3),
    sd = round(sd(valor),3),
    mediana = round(median(valor), 3),
    RIC = round(IQR(valor), 3),
    Q1 = round(quantile(valor, 0.25), 3),
    Q3 = round(quantile(valor, 0.75), 3),
    minimo = round(min(valor), 3),
    maximo = round(max(valor), 3),
    asim = round(skewness(valor), 3),
    curtosis = round(kurtosis(valor), 3))

tabla_independientes |>
  knitr::kable(
    caption = "Estadísticas descriptivas de ceniza volante y edad",
    digits = 3,
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position", "scale_down"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.6: Estadísticas descriptivas de ceniza volante y edad


variables	n	media	sd	mediana	RIC	Q1	Q3	minimo	maximo	asim	curtosis
ceniza	1030	54.187	63.996	0	118.27	0	118.27	0	200.1	0.537	1.672
edad	1030	45.662	63.170	28	49.00	7	56.00	1	365.0	3.264	15.104

```

df_clean |>
  ggplot(aes(x = ceniza)) +
  geom_histogram(
    aes(y = after_stat(density)),
    binwidth = 10,           # Intervalos de 10 kg/m³
    fill = "#d95f02",        # Tono naranja / teja
    color = "white",
    alpha = 0.6
  ) +
  geom_density(color = "#d95f02", linewidth = 1.2) +
  labs(

```


```
title = "Distribución del contenido de Ceniza Volante",  
x = "Ceniza Volante (kg/m³)",  
y = "Densidad"  
) +  
theme_bw()
```



La distribución es fuertemente bimodal e inflada en ceros. Presenta una concentración masiva en los 0 kg/m³ correspondiente a las mezclas tradicionales de control (55% de la muestra), seguida de un segundo agrupamiento entre los 80 y 160 kg/m³ en aquellas formulaciones donde sí se substituyó cemento por ceniza. Esta notable asimetría y falta de continuidad confirma la **no normalidad** de la variabl.

```
df_clean |>  
ggplot(aes(x = edad)) +
```

```
geom_histogram(  
  aes(y = after_stat(density)),  
  binwidth = 14,          # Intervalos de 14 días (2 semanas)  
  fill = "#7570b3",       # Tono violeta  
  color = "white",  
  alpha = 0.6  
) +  
geom_density(color = "#7570b3", linewidth = 1.2) +  
labs(  
  title = "Distribución del Tiempo de Curado",  
  x = "Tiempo de Curado (Días)",  
  y = "Densidad"  
) +  
theme_bw()
```



La distribución exhibe un marcado sesgo positivo con picos, concentrando la

gran mayoría de las observaciones en los 28 días la cual es la edad estándar de diseño y en periodos tempranos (≤ 7 días). La densidad decae drásticamente a partir de los 56 días, extendiéndose en una cola larga hasta los 365 días, lo cual evidencia una distribución **no normal** explicada por el diseño experimental enfocado en etapas normativas de obra.


3.8 Anlisis Univariado de las variables

```
# 1. Boxplot de Ceniza Volante
p1 <- df %>%
  ggplot(aes(x = "", y = `Fly Ash (component 3)(kg in a m^3 mixture)`)) +
  geom_boxplot(fill = "#d62728", alpha = 0.7) +
  labs(
    title = "Ceniza Volante (Fly Ash)",
    y = "Ceniza Volante (kg/m³)",
    x = ""
  ) +
  theme_bw()

# 2. Boxplot de Edad de Curado
p2 <- df %>%
  ggplot(aes(x = "", y = `Age (day)`)) +
  geom_boxplot(fill = "#e377c2", alpha = 0.7) +
  labs(
    title = "Tiempo de Curado",
    y = "Edad (Días)",
    x = ""
  ) +
  theme_bw()

# 3. Boxplot de Resistencia a la Compresión (Target / Variable Respuesta)
p3 <- df %>%
  ggplot(aes(x = "", y = `Concrete compressive strength(MPa, megapascals)`)) +
  geom_boxplot(fill = "#bcbd22", alpha = 0.7) +
  labs(
    title = "Resistencia a la Compresión",
    y = "Resistencia (MPa)",
    x = ""
  ) +
  theme_bw()
```

p1



3.8.1 Analisis boxplot Fly Ash


Se observa una distribución atípica con alta dispersión de los datos, además por la tabla anterior la media del uso de ceniza en las mezclas es $54.2\text{kg}/\text{m}^3$ y una desviación estándar de $64\text{kg}/\text{m}^3$

Sin embargo el diagrama de caja muestra que el 50% de los valores de ceniza coincide con el límite inferior, esto indica que el 50% de las mezclas no contienen ceniza volante. Por otra parte, el 75% de las observaciones contienen una cantidad de ceniza menor o igual a $118.6\text{kg}/\text{m}^3$, mientras que el migote señala mezclas con un máximo de $201.1\text{kg}/\text{m}^3$, no se evidencia ningún valor atípico.

¿porque hay este comportamiento de los datos centrado en cero? esto se debe a que el conjunto de datos contiene mezclas de control convencionales elaboradas exclusivamente con cemento tradicional para servir de base comparativa. Por ende, la ceniza volante actúa como un componente opcional.

3.8.2 Analisis boxplot tiempo de curado

p2



La variable Age (días de curado) presenta una concentración en edades tempranas y una gran dispersión, reflejada en un tiempo promedio de curado de 45.7 días y una desviación estándar de 63.2 días.


El boxplot nos permite observar una distribución sesgada a la derecha, también el 50% de las muestras fueron ensayadas a los 28 días o menos, el 25% inferior

corresponde a edades tempranas iguales o menores a 7 días, y el 75% central se concentra por debajo de los 56 días. No obstante, el diagrama de caja evidencia una serie de **valores extremos** en la parte superior, con ensayos a los 90, 180, 270 y hasta un máximo de 365 días es decir un año completo de curado.

¿Por qué existen valores atípicos tan elevados?

En la práctica de la ingeniería civil, los ensayos estándar de control de calidad se realizan de forma rutinaria a los 7, 14 y principalmente a los 28 días. Los tiempos de curado prolongados (> 90 días) son ensayos de investigación concebidos para evaluar la durabilidad a largo plazo y la reacción tardía de adiciones minerales como la ceniza volante.

p3




Para la variable objetivo “resistencia”, se observa un comportamiento mucho más homogéneo y balanceado, con un promedio de resistencia de 35.8 MPa y una desviación estándar de 16.7 MPa.

El 50% de los datos tienen una resistencia menor o igual a 34.5 MPa, mostrando una **notable cercanía con el promedio de resistencia de las mezclas de concreto (35.8 MPa)**. En cuanto al rango intercuartílico, el 25% de las mezclas con menor resistencia registran valores iguales o inferiores a 23.7 MPa, mientras que el 75% de las muestras se sitúan por debajo de los 46.1 MPa. Los bigotes abarcan un rango que va desde un mínimo de 2.3 MPa (concreto de muy baja resistencia) hasta aproximadamente los 80.0 MPa. Se aprecian únicamente unos pocos **valores atípicos superiores** que alcanzan un máximo de 82.6 MPa.

3.9 Analisis Bivariado

```
df_clean |>  
  ggpairs()
```



3.9.1 Creacion de nuevas variables

```
df_fe <- df_clean |>
  mutate(
    # 1. Razón Agua / Cementante (Agua / [Cemento + Ceniza])
    razon_agua_cementante = agua / (cemento + ceniza),

    # 2. Porcentaje de Cemento sustituido por Ceniza (0% a ~50%)
    pct_ceniza = (ceniza / (cemento + ceniza)) * 100,

    # 3. Clasificación del reemplazo en niveles (para futuros ANOVAs)
    nivel_ceniza = factor(case_when(
      pct_ceniza == 0 ~ "0% (Control)",
      pct_ceniza > 0 & pct_ceniza <= 20 ~ "Bajo (<= 20%)",
      pct_ceniza > 20 ~ "Alto (> 20%)"
    ), levels = c("0% (Control)", "Bajo (<= 20%)", "Alto (> 20%)")),

    # 4. Transformación Logarítmica de la Edad (Linealiza la ganancia de resistencia)
    log_edad = log(edad),

    # 5. Etapas estándar de curado
    etapa_curado = factor(case_when(
      edad <= 7 ~ "Temprano (<= 7d)",
      edad > 7 & edad <= 28 ~ "Estándar (14-28d)",
      edad > 28 ~ "Tardío (> 28d)"
    ), levels = c("Temprano (<= 7d)", "Estándar (14-28d)", "Tardío (> 28d)"))
  )
```

3.9.2 Tabla descriptiva de las nuevas variables

```
tabla_nuevas_numericas <- df_fe |>
  select(razon_agua_cementante, pct_ceniza, log_edad) |>
  pivot_longer(
    cols = everything(),
    names_to = "variable",
    values_to = "valor"
  ) |>
  group_by(variable) |>
  summarise(
    n = sum(!is.na(valor)),
    media = mean(valor, na.rm = TRUE),
    sd = sd(valor, na.rm = TRUE),
```

```

    mediana = median(valor, na.rm = TRUE),
    minimo = min(valor, na.rm = TRUE),
    maximo = max(valor, na.rm = TRUE),
    asim = skewness(valor, na.rm = TRUE),
    curtosis = kurtosis(valor, na.rm = TRUE),
    .groups = "drop"
  )

tabla_nuevas_numericas |>
  knitr::kable(
    caption = "Estadísticas descriptivas de las nuevas variables numericas",
    digits = 3,
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position", "scale_down"),
    full_width = FALSE,
    position = "center"
  )

```

Table 3.7: Estadísticas descriptivas de las nuevas variables numericas

variable	n	media	sd	mediana	minimo	maximo	asim	curtosis
log_edad	1030	3.165	1.191	3.332	0.000	5.900	-0.151	2.642
pct_ceniza	1030	15.526	18.788	0.000	0.000	58.841	0.649	1.859
razon_agua_cementante	1030	0.612	0.278	0.548	0.266	1.882	1.965	7.529

```

tabla_nuevas_categoricas <- bind_rows(
  df_fe |>
    count(nivel_ceniza, name = "frecuencia") |>
    transmute(variable = "nivel_ceniza", categoria = as.character(nivel_ceniza), frecuencia),
  df_fe |>
    count(etapa_curado, name = "frecuencia") |>
    transmute(variable = "etapa_curado", categoria = as.character(etapa_curado), frecuencia)
)

tabla_nuevas_categoricas |>
  knitr::kable(
    caption = "Frecuencias de las nuevas variables categoricas",
    format = ifelse(knitr::is_latex_output(), "latex", "html")
  ) |>
  kableExtra::kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = c("striped", "hold_position"),
  )

```

```

full_width = FALSE,
position = "center"
)

```

Table 3.8: Frecuencias de las nuevas variables categoricas

variable	categoria	frecuencia
nivel_ceniza	0% (Control)	566
nivel_ceniza	Bajo ($\leq 20\%$)	43
nivel_ceniza	Alto ($> 20\%$)	421
etapa_curado	Temprano ($\leq 7d$)	262
etapa_curado	Estándar (14-28d)	487
etapa_curado	Tardío ($> 28d$)	281

3.10 Pruebas de normalidad

```
# --- 1. PRUEBAS ESTADÍSTICAS DE NORMALIDAD ---
```

```
# Prueba de Shapiro-Wilk para la variable de respuesta
shapiro.test(df_clean$resistencia)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_clean$resistencia
## W = 0.97979, p-value = 0.00000000009023
```

```
# Prueba de Shapiro-Wilk para las variables independientes
shapiro.test(df_clean$ceniza)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_clean$ceniza
## W = 0.76201, p-value < 0.00000000000000022
```

```
shapiro.test(df_clean$edad)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: df_clean$edad  
## W = 0.59071, p-value < 0.00000000000000022
```

```
shapiro.test(df_clean$cemento)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: df_clean$cemento  
## W = 0.95896, p-value < 0.00000000000000022
```

```
shapiro.test(df_clean$agua)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: df_clean$agua  
## W = 0.9804, p-value = 0.0000000001473
```

```
shapiro.test(df_clean$agregado_grueso)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: df_clean$agregado_grueso  
## W = 0.98245, p-value = 0.0000000008346
```

```
lapply(df_clean, shapiro.test)
```

```
## $cemento  
##  
## Shapiro-Wilk normality test  
##  
## data: X[[i]]  
## W = 0.95896, p-value < 0.00000000000000022  
##  
##  
## $escoria  
##
```


```
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.81241, p-value < 0.00000000000000022
##
##
## $ceniza
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.76201, p-value < 0.00000000000000022
##
##
## $agua
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.9804, p-value = 0.0000000001473
##
##
## $superplast
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.86605, p-value < 0.00000000000000022
##
##
## $agregado_grueso
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.98245, p-value = 0.0000000008346
##
##
## $agregado_fino
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.98067, p-value = 0.0000000001843
##
##
```

```
## $edad
##
##  Shapiro-Wilk normality test
##
## data:  X[[i]]
## W = 0.59071, p-value < 0.00000000000000022
##
##
## $resistencia
##
##  Shapiro-Wilk normality test
##
## data:  X[[i]]
## W = 0.97979, p-value = 0.00000000009023
```

3.10.1 2. VALIDACIÓN VISUAL (Q-Q PLOTS)


```
# Gráfico para la Resistencia
qqnorm(df_clean$resistencia, pch = 1, frame = FALSE,
       main = "Gráfico Q-Q: Resistencia a la Compresión")
qqline(df_clean$resistencia, col = "red", lwd = 2)
```

Gráfico Q-Q: Resistencia a la Compresión



```
# Gráfico para la Edad
qqnorm(df_clean$edad, pch = 1, frame = FALSE,
      main = "Gráfico Q-Q: Tiempo de Curado (Edad)")
qqline(df_clean$edad, col = "red", lwd = 2)
```

Gráfico Q-Q: Tiempo de Curado (Edad)



1. Interpretación del Gráfico Q-Q para la Resistencia a la Compresión

Comportamiento central: En el centro del gráfico, la gran mayoría de los puntos se alinean bastante bien sobre la línea diagonal roja. Esto indica que los valores medios de resistencia (alrededor de los 35 MPa) tienen un comportamiento muy cercano a una distribución simétrica normal.

Desviación en los extremos (Colas): El gráfico seguramente muestra que los puntos se separan ligeramente de la línea roja en el extremo inferior (esquina inferior izquierda) y en el extremo superior (esquina superior derecha).

Conclusión: Esta pequeña desviación en los extremos es típica de variables que están acotadas (la resistencia no puede ser negativa) o que tienen unos pocos valores atípicamente altos (mezclas de muy alto rendimiento). Esto concuerda con tu prueba de Shapiro-Wilk ($W = 0.97979$), donde la variable se ve “casi” normal en el centro, pero las ligeras desviaciones en las colas hacen que la prueba estadística la rechace matemáticamente.

```
# Pruebas estadísticas (Shapiro-Wilk)
```

```
shapiro.test(df_clean$cemento)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_clean$cemento
## W = 0.95896, p-value < 0.00000000000000022
```

```
shapiro.test(df_clean$agua)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_clean$agua
## W = 0.9804, p-value = 0.0000000001473
```

```
shapiro.test(df_clean$agregado_grueso)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df_clean$agregado_grueso
## W = 0.98245, p-value = 0.0000000008346
```

```
# (Puedes copiar y pegar para el resto de variables)
```

```
# Aplicar Shapiro-Wilk a todas las columnas de df_clean de un solo golpe
resultados_normalidad <- lapply(df_clean, shapiro.test)
resultados_normalidad
```

```
## $cemento
##
##  Shapiro-Wilk normality test
##
## data:  X[[i]]
## W = 0.95896, p-value < 0.00000000000000022
##
##
## $escoria
##
##  Shapiro-Wilk normality test
```

```
##
## data: X[[i]]
## W = 0.81241, p-value < 0.00000000000000022
##
##
## $ceniza
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.76201, p-value < 0.00000000000000022
##
##
## $agua
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.9804, p-value = 0.0000000001473
##
##
## $superplast
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.86605, p-value < 0.00000000000000022
##
##
## $agregado_grueso
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.98245, p-value = 0.0000000008346
##
##
## $agregado_fino
##
## Shapiro-Wilk normality test
##
## data: X[[i]]
## W = 0.98067, p-value = 0.0000000001843
##
##
## $edad
```

```
##
## Shapiro-Wilk normality test
##
## data:  X[[i]]
## W = 0.59071, p-value < 0.00000000000000022
##
##
## $resistencia
##
## Shapiro-Wilk normality test
##
## data:  X[[i]]
## W = 0.97979, p-value = 0.00000000009023
```

Al evaluar las nueve variables del conjunto de datos mediante la prueba de normalidad de Shapiro-Wilk, se obtienen las siguientes conclusiones estadísticas para documentar en tu Análisis Exploratorio de Datos (EDA):

Rechazo generalizado de la normalidad: Todas las variables analizadas arrojaron un p-valor estrictamente inferior al nivel de significancia de 0.05. En consecuencia, se rechaza la hipótesis nula (H_0) para todo el conjunto de datos y se concluye estadísticamente que ninguna variable sigue una distribución normal perfecta.


Variables con desviación severa (Alta asimetría o inflación de ceros): Las variables edad ($W = 0.59071$), ceniza ($W = 0.76201$), escoria ($W = 0.81241$) y superplast ($W = 0.86605$) presentan las violaciones más fuertes al supuesto de normalidad, reflejadas en los estadísticos W más bajos y p-valores menores a 0.00000000000000022. Esto corrobora el análisis gráfico preliminar: la edad tiene saltos marcados por los tiempos estándar de curado, mientras que los aditivos presentan una enorme concentración de ceros (mezclas que no los incluyen).

Variables con aproximación a la normalidad (Sensibilidad de la prueba): Las variables agregado_grueso ($W = 0.98245$), agregado_fino ($W = 0.98067$), agua ($W = 0.9804$), resistencia ($W = 0.97979$) y cemento ($W = 0.95896$) poseen un estadístico W muy cercano a 1. Aunque sus p-valores obligan a rechazar la normalidad teórica (fluctuando en el orden de 10^{-10} a 10^{-12}), la estructura de sus datos es razonablemente simétrica y acampanada. El rechazo se explica principalmente por la hipersensibilidad de la prueba de Shapiro-Wilk ante tamaños de muestra grandes ($N = 1030$), donde cualquier desviación milimétrica de la campana de Gauss resulta estadísticamente significativa.


Impacto metodológico para el modelo: Dado que las variables no son normales por naturaleza, no se recomienda utilizar correlaciones paramétricas simples (como Pearson) para medir sus relaciones, sino alternativas robustas como la correlación de Spearman. Además, la regresión múltiple exigirá validar la normalidad directamente sobre los residuos predictivos y no sobre estas variables

independientes aisladas, contemplando posibles transformaciones logarítmicas para las variables del primer grupo (edad y aditivos).

```
# Gráficos Q-Q para ver visualmente la distribución  
qqnorm(df_clean$agua, pch = 1, frame = FALSE, main = "Gráfico Q-Q: Cantidad de Agua")  
qqline(df_clean$agua, col = "red", lwd = 2)
```



```
qqnorm(df_clean$cemento, pch = 1, frame = FALSE, main = "Gráfico Q-Q: Cemento")  
qqline(df_clean$cemento, col = "red", lwd = 2)
```



2. Interpretación del Gráfico Q-Q para el Tiempo de Curado (Edad)

Falta de alineación y forma de “escalera”: Al mirar este gráfico, los puntos no siguen una línea recta continua. En su lugar, vas a ver agrupaciones densas de puntos dispuestas de forma horizontal (como si fueran escalones) y muy separadas de la línea roja de referencia.

Por qué ocurre esto (Asimetría severa): Esta desviación extrema ocurre porque el tiempo de curado no es una variable continua natural en este experimento. Los laboratoristas toman medidas en días fijos normativos (3, 7, 14, 28, 56 días, etc.), creando “saltos” en la distribución. Además, como la enorme mayoría de las pruebas se hacen a los 28 días y muy pocas llegan a un año (365 días), la distribución tiene un sesgo altísimo hacia la izquierda.

Conclusión: La trayectoria de los puntos corrobora visualmente el pésimo resultado de su prueba de Shapiro-Wilk ($W = 0.59071$). La edad presenta una desviación radical respecto al modelo de campana de Gauss, confirmando una distribución discreta, marcadamente sesgada hacia la derecha (valores tempranos) y con una cola larga.